

机器视觉-实验报告

实验 1-单目深度与点云重建

曹航硕（3240101938）、吴朝臣（3240106219）

1 实验设置

1.1 数据与运行条件

采用课程提供的 NYU Depth V2 教学数据，共 8 张 640×480 的室内 RGB 图像，编号为 0001、0101、0201、0401、0601、0801、1001 和 1201。参考值为与 RGB 对齐的 Kinect 原始实测深度，不使用填补后的深度。有效域沿用数据包掩膜：在行区间 $[45, 471)$ 、列区间 $[41, 601)$ 内，选取有限且满足 $0.1 < g < 10$ m 的像素，其中 g 为真实深度。

实验在 Apple M5、24 GB 统一内存的 macOS 设备上运行，采用 PyTorch MPS 后端。软件环境为 Python 3.12、PyTorch 2.7.1、NumPy 1.26.4、OpenCV 4.10.0 和 Open3D 0.19.0。推理使用评估模式、float32 精度和单张输入，不进行训练或微调。

1.2 模型配置与对比方案

两种模型均采用 Small (ViT-S/14) 规格，代码以官方仓库提交 a561b849 为基础。Depth Anything V2 使用官方相对深度权重；Depth Anything V2 (Metric Depth) 使用 Hypersim 室内权重，最大预测深度设为 20 m。分别设置输入尺寸为 280 和 518，保持宽高比缩放并将尺寸调整为 14 的倍数，实际网络输入宽高为 378×280 和 686×518 ；输出均恢复为 640×480 。

公平比较的设计：Depth Anything V2 的预测已利用真值校正尺度与偏移，不能直接与未校正的 Depth Anything V2 (Metric Depth) 比较误差。我们先将后者的米制深度取倒数，再按相同规则对齐、裁剪，比较两种模型的几何质量；同时保留其原始米制输出，评价绝对距离精度。因此，每种输入尺寸设置以下三组评估。

六组评估均使用相同图像、真值有效域和相机内参。

表 1 评估分组与深度处理方式

评估组	处理方式
Depth Anything V2	对齐后：直接以模型输出的相对逆深度为 q ，拟合尺度与偏移后恢复深度
Depth Anything V2 (Metric Depth)	对齐后：将米制预测 d 转为 $q = 1/d$ ，再按相同规则对齐与裁剪
Depth Anything V2 (Metric Depth)	原始米制：直接评估米制预测，不拟合尺度、不裁剪预测值

两组对齐评估均在每张图的全部有效像素上，分别用最小二乘拟合一组 a, b ，使 $aq + b$ 接近 $1/g$ ，再计算 $z = 1/(aq + b)$ 。非正的对齐逆深度按 10 m 处理，最终深度裁剪至 $[0.1, 10]$ m。拟合与评估使用同一有效域，因此对齐后的误差不代表独立测距精度。

1.3 点云、指标与计时约定

使用数据包内参将预测深度与参考深度反投影到同一相机坐标系，在相同有效像素位置比较三维对应点，不额外进行点云配准。分别计算 AbsRel、深度 RMSE 和 XYZ RMSE；AbsRel 无量纲，后两项单位为米。先逐图计算指标，再对 8 张图等权求算术平均，不将所有像素合并后计算总体 RMSE。

计时包含图像预处理、模型预测和输出恢复到原图尺寸的过程，不包含模型加载、文件读写、点云生成和评估。每张图记录一次推理耗时，再计算 8 张图的平均值。

2 结果分析

2.1 Depth Anything V2: 不同输入尺寸的结果与分析

为比较输入尺寸的影响，我们使用同一个 Depth Anything V2 模型和相同的 8 张图像，分别以 518 和 280 进行预测。两组结果采用相同的深度对齐与评估方法，并统一深度图的颜色范围，比较图像效果、误差和耗时。

2.1.1 深度预测对比




图 1 8 张图像的深度预测对比。每组三行依次为原图、518 和 280 输入尺寸的预测；深度经对齐后统一着色，颜色越深表示距离越远。

两种输入尺寸都能区分墙面、地面和家具的前后关系，整体结构较接近。518 在部分细节上更清楚，例如 0401 的婴儿床栏杆、0801 的椅背和桌椅边缘；280 的这些区域更平滑。

2.1.2 误差与耗时比较

表 2 两种输入尺寸的逐图误差及均值（对齐后；粗体为同一行、同一指标的较小值）

图像编号	AbsRel		深度 RMSE / m		XYZ RMSE / m	
	518	280	518	280	518	280
0001	0.0262	0.0210	0.0974	0.0830	0.1067	0.0906
0101	0.1657	0.1823	0.6835	0.6230	0.7281	0.6647
0201	0.1026	0.1588	0.8290	1.2179	0.8749	1.3046
0401	0.0559	0.0394	0.1821	0.1511	0.1958	0.1627
0601	0.0381	0.0386	0.2225	0.2445	0.2368	0.2622
0801	0.0943	0.0749	0.5776	0.4644	0.6177	0.4908
1001	0.0699	0.0640	0.2238	0.2195	0.2422	0.2359
1201	0.0513	0.0638	0.1744	0.2123	0.1865	0.2283
均值	0.0755	0.0804	0.3738	0.4020	0.3986	0.4300

误差比较。我们对每张图分别计算三项误差，再取 8 张图的平均值。518 的平均 AbsRel、深度 RMSE 和 XYZ RMSE 相比 280 分别降低约 6.0%、7.0% 和 7.3%，整体上略有改善。

不过，输入尺寸更大并不意味着每张图都更准确。例如 0201 的深度 RMSE 从 1.2179 m 降至 0.8290 m，改善较明显；0001 和 0401 的三项误差则都是 280 更低。因此，需要结合多张图的结果判断，不能只看某一张图的效果。

表 3 两种输入尺寸的推理耗时（粗体为较短耗时）

输入尺寸	实际输入宽高	平均耗时 / ms	8 张总耗时 / s
518	686 × 518	140.7	1.126
280	378 × 280	53.3	0.426

耗时比较。本次运行中，518 的平均耗时约为 280 的 2.64 倍。518 的平均误差略低、部分细节更清楚，而 280 用时更短，且仍能保留主要场景结构；两者体现了精度与速度之间的取舍。

2.1.3 点云重建示意



图 2 0001 的点云示意：左为参考深度生成的点云，右为 518 输入尺寸的预测点云。两者使用相同视角与显示比例，并用原图颜色着色。

预测点云能够重建墙面、座椅和柜台的基本位置关系，与参考点云的整体形状接近，但局部轮廓仍有偏差。点云图主要用于展示重建效果，尺寸变化带来的精度差异以表中的 XYZ RMSE 为准。

2.2 Depth Anything V2 与 Depth Anything V2 (Metric Depth) 的对比分析

2.2.1 深度与点云精度比较

我们在相同的 8 张图上比较两种模型的结果，分别设置 518 和 280 两种输入尺寸。两者采用相同的有效像素、相机内参及对齐、裁剪规则，具体方法见 1.2。同时保留 Depth Anything V2 (Metric Depth) 的原始米制结果，观察其直接测距能力。

表 4 两种模型的深度与点云误差（8 张图等权均值；粗体为同尺寸下两种模型对齐后的最优值）

模型	尺寸	处理	AbsRel	深度 RMSE / m	XYZ RMSE / m
Depth Anything V2	518	对齐后	0.0755	0.3738	0.3986
Depth Anything V2 (Metric Depth)	518	对齐后	0.1002	0.4792	0.5156
Depth Anything V2 (Metric Depth)	518	原始米制	0.2222	0.7055	0.7534
Depth Anything V2	280	对齐后	0.0804	0.4020	0.4300
Depth Anything V2 (Metric Depth)	280	对齐后	0.1190	0.6226	0.6694
Depth Anything V2 (Metric Depth)	280	原始米制	0.5940	1.6117	1.7377

相同对齐条件下，**Depth Anything V2** 的三项平均误差在两种输入尺寸下都更低。说明在本次实验中，能够输出米制深度，并不意味着对齐后的深度和点云一定更准确。

2.2.2 对齐前后的差距变化

为直观体现对齐的效果，我们以同一输入尺寸下 **Depth Anything V2** 对齐后的误差为基准，计算 Depth Anything V2 (Metric Depth) 的误差超出比例，即“（米制深度误差 ÷ 基准误差 - 1）× 100%”。以下比例由 8 张图的指标均值计算。

表 5 米制深度误差超出基准的比例（原始米制 → 对齐后；粗体为较小差距）

输入尺寸	AbsRel	深度 RMSE	XYZ RMSE
518	194.3% → 32.8%	88.8% → 28.2%	89.0% → 29.4%
280	639.1% → 48.0%	300.9% → 54.9%	304.1% → 55.7%

对齐后，两种模型的误差差距显著缩小。在 518 下，深度 RMSE 超出基准的比例从 88.8% 降至 28.2%，XYZ RMSE 从 89.0% 降至 29.4%；280 下的两项差距也从约 300% 降至约 55%。因此，两种模型对齐后的表现更接近，但仍存在一定差距。以米制预测自身为参照，518 下对齐后的深度 RMSE 和 XYZ RMSE 分别降低了 32.1% 和 31.6%。

上述变化来自对齐与裁剪的共同作用，原始米制比例仅用于观察处理效果，不作为公平排名。两种模型的训练方式和数据也不同，不能将精度差别全部归因于是否包含尺度信息。

2.2.3 尺度信息的作用

结合课上讲的成像关系，在相机内参已知时，一个像素只能确定一条从相机光心出发的射线，深度决定三维点位于这条射线的哪一处。如果缺少深度，射线上多个不同位置的点都可以投影到同一个像素，因此单凭像素位置无法唯一恢复三维点。

尺度信息使重建的深度和空间大小具有实际意义。例如，将场景中的所有三维坐标同时放大两倍，投影到图像上的位置仍可以保持不变，但真实距离和物体大小已经改变。尺度信息用于确定真实的距离与大小，使点云能够用于测距和尺寸估计，而不只是展示相对的前后关系。

在本实验中，Depth Anything V2 的输出没有米制单位，我们利用参考深度进行对齐，为结果补充尺度与偏移信息；Depth Anything V2 (Metric Depth) 则通过米制深度训练直接预测以米为单位的深度，但预测仍可能存在误差。

因此，尺度信息为相对重建补充真实尺度约束，但仅靠一个尺度不能唯一确定整幅图的深度，各像素的深度仍需预测或测量。本实验分别评估对齐后的几何精度与原始米制精度，以区分结构恢复效果和绝对距离估计能力。

3 总结

3.1 对学习方法的直观认识

本次实验让我们直观体验到了基于学习的单目深度预测方法已经能够达到较好的效果。仅输入一张普通的 RGB 图像，Depth Anything V2 就能预测出场景中较清晰的前后关系，区分墙面、地面和家具，并保留部分细小结构。经过深度对齐和点云生成后，我们还能够从不同角度观察重建出的三维场景。这让我们认识到，模型从数据中学到的经验能够为深度恢复提供有效线索，也让课上的三维重建过程变得更加直观。

3.2 对补充深度信息的理解与后续思考

实验也加深了我们对课上所学内容的理解：从二维图像恢复三维空间时，像素位置只能确定一条射线，缺少的深度信息需要通过其他途径补充。本次实验中，模型先给出相对深度结构，再利用真实深度标注校正尺度与偏移。真实标注提供了较可靠的尺度约束，使预测结果能够以米为单位表示，并生成与参考场景较接近的点云。Depth Anything V2 (Metric Depth) 在对齐后误差明显下降，也让我们看到了这类补充信息对重建效果的帮助。

因此，我们认为，后续要继续提高三维恢复效果，除了改进模型，也可以寻找更多可靠的方式来补充深度约束。例如，让机器人主动移动，从不同位置拍摄同一场景，形成类似双目的多视角观测；结合相机位姿和已知的移动距离，利用视差估计深度。这样就能把模型学到的场景经验与实际观测得到的几何信息结合起来，尝试在没有真实深度标注的情况下，获得更准确、具有真实尺度的三维重建。